Metodi Matematici e Statistici per le Decisioni Economiche

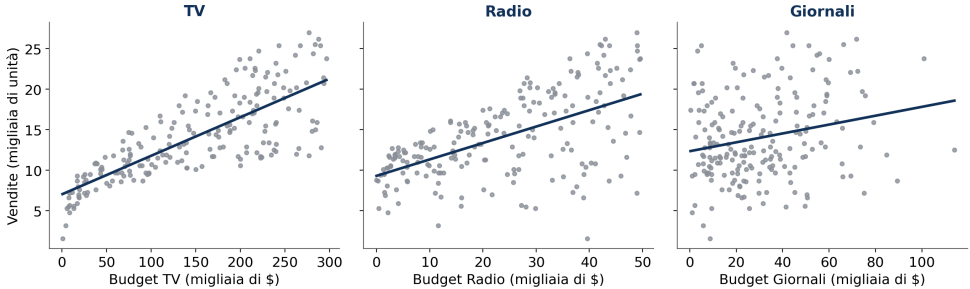
Corso di Laurea Magistrale in Management, Imprese e Mercati
2026-2027 — Lezione 2: Prevedere un numero, la regressione lineare

Vincenzo Nardelli



vincenzo.nardelli@unicatt.it · vincnardelli.com/msd

Dove eravamo rimasti



Vendite di un prodotto in **200 mercati**, con il budget speso in pubblicità su TV, radio e giornali. Volevamo un modello Vendite = f(TV, Radio, Giornali) + ϵ. **Oggi:** la f più semplice che esista, una retta.

Fonte: dataset Advertising, James, Witten, Hastie, Tibshirani, *An Introduction to Statistical Learning*.

Le domande del direttore marketing

1. C'è una relazione tra budget pubblicitario e vendite?
2. Quanto è forte?
3. **Quanto rende** ogni mille dollari in più su un mezzo?
4. Quali mezzi contano davvero, e quali no?
5. Quanto bene possiamo prevedere le vendite del prossimo mercato?
6. Spendere su due mezzi insieme rende più della somma delle parti?

Sono domande di business. La regressione lineare risponde a tutte e sei, e alla fine di domani torniamo qui a controllare.

La regressione lineare semplice

$$Y = \beta_0 + \beta_1 X + \epsilon$$

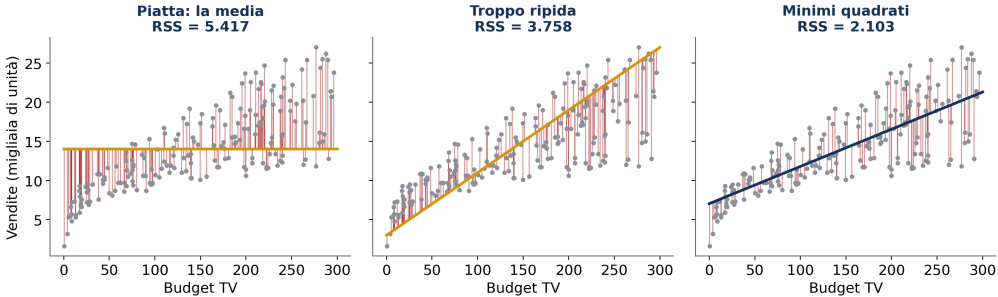
β_0, **intercetta**
le vendite attese con budget TV pari a zero.

β_1, **pendenza**
di quanto cambiano in media le vendite per un'unità in più di X.

ϵ, **errore**
tutto quello che la retta non vede: prezzi, concorrenti, stagione, caso.

β_0 e β_1 sono **sconosciuti**. Li stimiamo dai dati: le stime si scrivono con il cappello, $\hat{\beta}_0$ e $\hat{\beta}_1$.

Tra tutte le rette possibili, quale?



Per ogni retta misuriamo quanto sbaglia: le linee rosse. Le eleviamo al quadrato e le sommiamo. Quella con la somma più piccola è la retta dei **minimi quadrati**.

Previsione e residuo

Per il mercato i con budget x_i la retta prevede

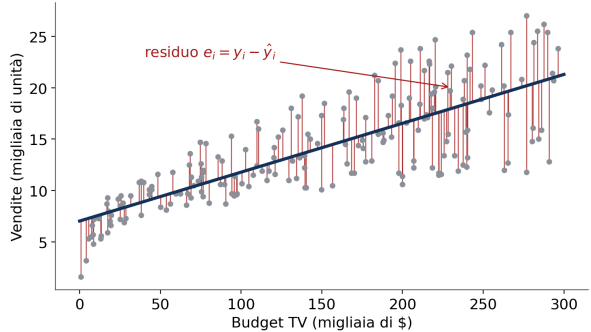
$$\hat{y}_i = \hat{\beta}_0 + \hat{\beta}_1 x_i$$

Il **residuo** è quanto la previsione sbaglia:

$$e_i = y_i - \hat{y}_i$$

La somma dei quadrati dei residui:

$$RSS = e_1^2 + e_2^2 + \cdots + e_n^2$$



Le stime dei minimi quadrati

I valori che rendono minimo l'RSS hanno una formula chiusa:

$$\hat{\beta}_1 = \frac{\sum_{i=1}^{n}(x_i - \bar{x})(y_i - \bar{y})}{\sum_{i=1}^{n}(x_i - \bar{x})^2} = \frac{\text{Cov}(X, Y)}{\text{Var}(X)} \qquad \hat{\beta}_0 = \bar{y} - \hat{\beta}_1 \bar{x}$$

- La pendenza è la **covarianza** della lezione 1, divisa per la varianza di X: ha lo stesso segno della correlazione.
- La retta passa sempre per il punto medio $(\bar{x}, \bar{y})$.
- Python fa il conto per noi. A noi resta leggere il risultato.

Il risultato sui dati Advertising

$$\widehat{\text{Vendite}} = 7{,}03 + 0{,}0475 \times \text{TV}$$

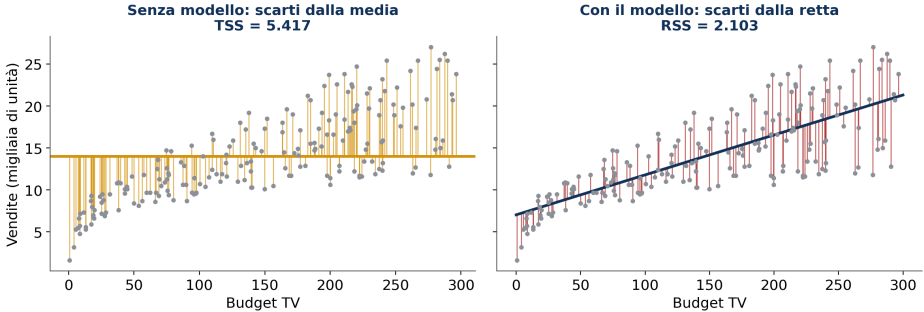
7.033
unità vendute in un mercato senza pubblicità TV

+47,5
unità vendute in più per ogni 1.000 $ di TV

21 $
il margine per unità sopra il quale la TV si ripaga

Vendite in migliaia di unità, budget in migliaia di dollari: 0,0475 migliaia di unità sono 47,5 unità. Se ogni unità ci lascia più di $1.000/47{,}5 \approx 21$ dollari, mille dollari in TV si ripagano. È qui che il numero diventa una decisione.

Quanto spiega il modello? L'R^2



$$R^2 = 1 - \frac{RSS}{TSS} = 1 - \frac{2.103}{5.417} = 0{,}612$$

TSS: quanto variano le vendite attorno alla loro media. RSS: quanto resta dopo aver usato la TV. La TV spiega il 61% della variabilità delle vendite tra i mercati.

R^2, correlazione ed errore tipico

0,782

correlazione tra TV e vendite (lezione 1)

0,612

$0{,}782^2$: con una sola X, R^2 è la correlazione al quadrato

3,26

RSE: di quanto sbaglia in media la previsione

$$RSE = \sqrt{\frac{RSS}{n-2}}$$

L'RSE è nell'unità di Y: in media sbagliamo di circa 3.260 unità, su vendite medie di 14.022. Un errore del 23%: per un budget nazionale va bene, per prevedere il singolo mercato è largo.

Prevedere le vendite

Budget TV	Vendite previste
0	7.033
100.000 $	11.786
200.000 $	16.540
400.000 $	26.047

Basta mettere il budget nella formula:

$$\hat{y} = 7{,}03 + 0{,}0475 \times x$$

Attenzione all'ultima riga. Nei dati il budget TV più alto è 296.400 $. A 400.000 $ stiamo **estrapolando**: nessuno ci garantisce che la retta continui così.

Le vendite non crescono all'infinito: prima o poi il mercato si satura. Domani vediamo quanto sono incerte queste previsioni.

Cosa la retta non dice

- La retta descrive un'**associazione**: nei mercati dove si spende di più in TV si vende di più.
- Non dice che la TV *causa* le vendite. Forse si spende di più in TV proprio nei mercati più grandi, dove si venderebbe comunque di più.
- Per dire "se aumento il budget, le vendite salgono" servono un esperimento o un'analisi del perché i budget sono diversi.

È la correlazione spuria della lezione 1, con una formula in più. La formula rende il numero più convincente, non più vero. La decisione resta di chi sa come sono stati assegnati i budget.

LAB 1 · Real estate

LAB Quanto vale una casa a Boston?

Un'agenzia immobiliare vuole capire quanto il livello socioeconomico di un quartiere pesa sul valore delle case, per consigliare investitori e pianificatori urbani.

Dati: `boston.csv`, 506 quartieri di Boston.

- `medv`: valore mediano delle case (migliaia di $), la variabile da prevedere
- `lstat`: % di popolazione a basso reddito
- `rm`: numero medio di stanze; `age`: % di case costruite prima del 1940; `dis`: distanza dai centri di lavoro

Notebook `lab_real_estate` sul sito, si apre in Colab. Il dizionario Python-R è nelle Guide.

LAB 1 · Le domande

1. Come sono distribuiti `lstat` e `medv`? Istogrammi e misure di sintesi.
2. Che relazione c'è tra `lstat` e `medv`? Grafico a dispersione e correlazione.
3. Stima `medv ~ lstat`. Come leggi intercetta e pendenza? Quanto vale l'R^2?
4. Che valore prevedi per quartieri con il 5%, il 10% e il 15% di popolazione a basso reddito?
5. Guarda il grafico con la retta: la relazione è davvero una retta?

Per la 5: aggiungi `geom_smooth(method="lm")` allo scatter. Ne riparliamo domani.

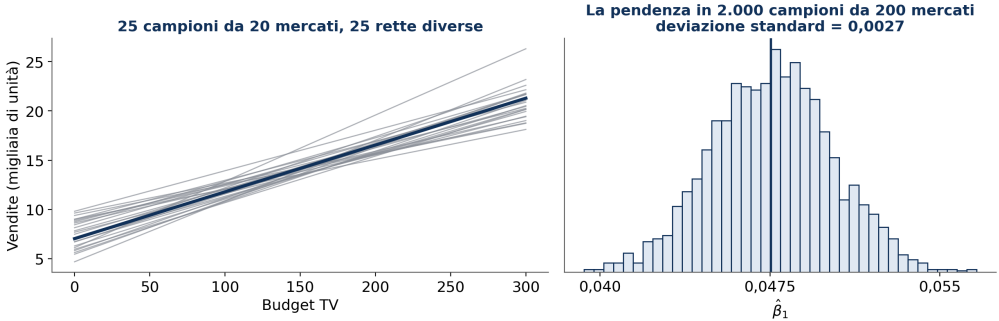
Ieri, in una slide

$$\widehat{\text{Vendite}} = 7{,}03 + 0{,}0475 \times \text{TV} \qquad R^2 = 0{,}612 \qquad \text{RSE} = 3{,}26$$

- La retta dei minimi quadrati è quella che sbaglia meno, in somma dei quadrati.
- Ogni 1.000 $ in TV si associano a 47,5 unità vendute in più.
- La TV spiega il 61% delle differenze di vendita tra mercati.

Domanda di oggi: se avessimo osservato altri 200 mercati, avremmo trovato 47,5? O 30? O 0?

Altri dati, altra retta



Simulazione: generiamo nuovi mercati dal modello stimato e ristimiamo la retta ogni volta. La stima cambia da campione a campione. Quanto cambia, lo misura l'**errore standard**.

L'errore standard

$$SE(\hat{\beta}_1) = \sqrt{\frac{\sigma^2}{\sum_{i=1}^{n}(x_i - \bar{x})^2}} \qquad \sigma^2 = \text{Var}(\epsilon), \text{ stimata con } RSE^2$$

0,0027

errore standard di $\hat{\beta}_1$ calcolato dalla formula

0,0027

deviazione standard delle 2.000 pendenze simulate

=

la formula dice quanto la stima ballerebbe

L'errore standard è più piccolo se i dati sono tanti, se l'errore ϵ è piccolo, e se le X sono molto disperse: con budget tutti uguali non si capisce cosa succede cambiandoli.

Intervallo di confidenza

Un intervallo al 95% per β_1 è, approssimativamente,

$$\hat{\beta}_1 \pm 2 \cdot \text{SE}(\hat{\beta}_1) = 0{,}0475 \pm 2 \times 0{,}0027 = [\,0{,}042\,;\,0{,}053\,]$$

In parole: ogni 1.000 $ in TV si associano a un aumento tra **42 e 53 unità** vendute. Se ripetessimo la raccolta dei dati molte volte, il 95% degli intervalli costruiti così conterrebbe il valore vero.

Per la decisione conta l'estremo prudente: anche con 42 unità, sopra i 24 $ di margine per unità la TV si ripaga (1.000/42).

Test di ipotesi: la TV c'entra qualcosa?

Ipotesi nulla H_0: $\beta_1 = 0$
nessuna relazione tra TV e vendite

Alternativa H_A: $\beta_1 \neq 0$

Statistica test:

$$t = \frac{\hat{\beta}_1 - 0}{SE(\hat{\beta}_1)} = \frac{0{,}0475}{0{,}0027} = 17{,}7$$

Il p-value è la probabilità di osservare un |t| così grande se H_0 fosse vera.

Qui è minore di 0,0001: con $\beta_1 = 0$ un risultato così non capita praticamente mai. Rifiutiamo H_0.

Soglia abituale: p-value sotto 0,05. Non è una legge di natura, è una convenzione.

Come si legge la tabella dei risultati

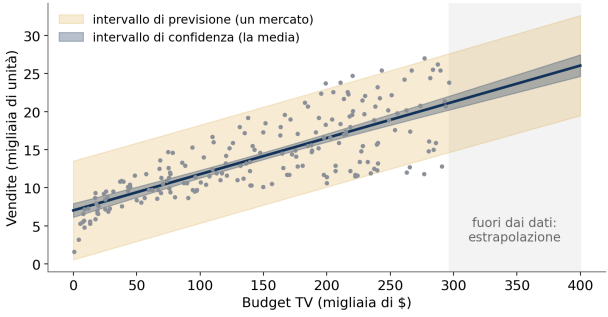
	Coef.	**Err. std.**	t	**p-value**	**IC 95%**
Intercetta	7,0326	0,4578	15,36	<0,0001	[6,13 ; 7,94]
TV	0,0475	0,0027	17,67	<0,0001	[0,042 ; 0,053]

n = 200 R^2 = 0,612 RSE = 3,26 F = 312,1

- **Coef.**: la stima. **Err. std.**: quanto ballerebbe con altri dati.
- t = Coef. / Err. std. Lontano da zero (oltre 2 in valore assoluto) vuol dire relazione chiara.
- **p-value** e **IC**: due modi di dire la stessa cosa. Se l'intervallo non contiene lo zero, il p-value è sotto 0,05.

È la tabella che Python stampa con `.summary()`: impariamo a leggerla, non a ricopiarla.

Prevedere: la media o il singolo mercato?



Budget TV di 100.000 $:

- **previsione**: 11.786 unità
- **media** di tutti i mercati con quel budget: tra 11.268 e 12.305
- **un singolo** mercato: tra 5.339 e 18.233

Per pianificare il budget nazionale conta la media. Per promettere un obiettivo al responsabile di una zona conta l'intervallo largo.

La regressione lineare multipla

$$Y = \beta_0 + \beta_1 X_1 + \beta_2 X_2 + \cdots + \beta_p X_p + \epsilon$$

$$\text{Vendite} = \beta_0 + \beta_1 \cdot \text{TV} + \beta_2 \cdot \text{Radio} + \beta_3 \cdot \text{Giornali} + \epsilon$$

- Le stime sono ancora quelle dei minimi quadrati: la somma dei residui al quadrato più piccola.
- β_j è l'effetto medio su Y di un'unità in più di X_j **a parità degli altri predittori**.

"A parità degli altri" è la frase più importante della lezione. Il coefficiente della radio risponde a: *tra due mercati con lo stesso budget TV e giornali, quanto vende di più quello che spende 1.000 $ in più in radio?*

Tre rette separate o un modello solo?

	Tre regressioni semplici		**Una regressione multipla**	
	Coef.	p-value	Coef.	p-value
TV	0,0475	<0,0001	0,0458	<0,0001
Radio	0,2025	<0,0001	0,1885	<0,0001
Giornali	**0,0547**	**0,0011**	**−0,0010**	**0,8599**

Da soli, i giornali sembrano funzionare: +54,7 unità per 1.000 $, risultato significativo. Nel modello con tutti e tre, il loro effetto **sparisce**. Quale dei due numeri crediamo?

Perché i giornali spariscono

	TV	Radio	Giornali	Vendite
TV	1	0,05	0,06	0,78
Radio		1	**0,35**	0,58
Giornali			1	0,23

- I mercati che spendono in radio spendono anche in giornali (correlazione 0,35).
- La radio fa vendere. Da soli, i giornali si prendono il merito della radio che viaggia con loro.
- Il modello multiplo confronta mercati con la stessa radio: lì i giornali non aggiungono nulla.

Decisione: tagliare il budget giornali non dovrebbe costare vendite. Una regressione semplice avrebbe suggerito il contrario.

Almeno un predittore serve? La statistica F

$$F = \frac{(TSS - RSS)/p}{RSS/(n - p - 1)}$$

H_0: tutti i β_j sono zero, nessun mezzo conta. Se F è molto più grande di 1, almeno un predittore serve.

570
statistica F
(p-value < 0,0001)

0,897
R^2: dal 61% con la sola TV
al 90% con tutti e tre

1,69
RSE: l'errore tipico
si dimezza (era 3,26)

R^2 aggiustato: aggiungere variabili ha un prezzo

- L'R^2 non scende mai quando si aggiunge una variabile, anche inutile.
- L'R^2 aggiustato penalizza il numero di predittori p:

$$R^2_{adj} = 1 - \frac{RSS/(n - p - 1)}{TSS/(n - 1)}$$

Modello	R^2	R^2_{adj}	RSE
TV + Radio + Giornali	0,8972	0,8956	1,686
TV + Radio	0,8972	**0,8962**	**1,681**

Togliendo i giornali l'R^2 resta uguale, l'R^2 aggiustato sale e l'errore scende: il modello più semplice è il migliore.

Quali variabili tenere?

Con p predittori i modelli possibili sono 2^p: con 40 variabili, più di mille miliardi. Due scorciatoie:

- **in avanti**: si parte da nessuna variabile e si aggiunge ogni volta quella che migliora di più;
- **all'indietro**: si parte da tutte e si toglie ogni volta quella con il p-value più alto.

Ci si ferma quando non si migliora più.

Saldo della carta di credito, 400 clienti di una banca: selezione in avanti con l'R^2 aggiustato

Passo	**Aggiungo**	R^2_{adj}
1	Rating	0,745
2	Reddito	0,874
3	Studente	0,949
4	Limite	0,952
5	Carte	0,954
stop	Età	< +0,001

Dopo tre passi il guadagno è minimo: un modello con tre variabili si spiega meglio a un comitato crediti.

Un predittore qualitativo: la variabile dummy

Una banca si chiede se i clienti proprietari di casa hanno un saldo diverso sulla carta di credito.

$$x_i = \begin{cases} 1 & \text{se il cliente } i \text{ è proprietario di casa} \\ 0 & \text{altrimenti} \end{cases} \qquad y_i = \beta_0 + \beta_1 x_i + \epsilon_i$$

	Coef.	**Err. std.**	t	**p-value**
Intercetta	509,80	33,13	15,39	<0,0001
Proprietario [Sì]	19,73	46,05	0,43	0,6685

β_0 è il saldo medio dei non proprietari (509,80 $); β_1 è la differenza dei proprietari (+19,73 $). Con un p-value di 0,67 la differenza non è distinguibile dal caso.

Più di due livelli: una dummy in meno

La regione del cliente ha tre livelli: Est, Sud, Ovest. Servono **due** dummy:

$$y_i = \beta_0 + \beta_1 \cdot \text{Sud}_i + \beta_2 \cdot \text{Ovest}_i + \epsilon_i$$

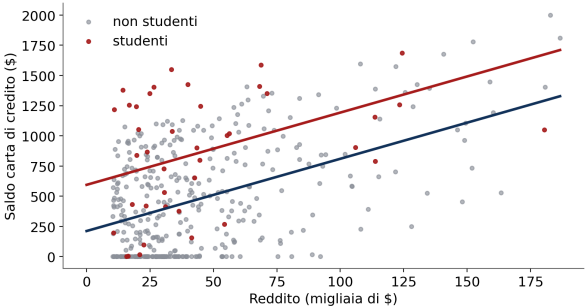
Il livello senza dummy, Est, è la **categoria di riferimento**: β_0 è la sua media, gli altri coefficienti sono differenze da Est.

	Coef.	p-value
Intercetta (Est)	531,00	<0,0001
Sud	−12,50	0,8255
Ovest	−18,69	0,7740

F = 0,04, p-value = 0,957

Python sceglie come riferimento il primo livello in ordine alfabetico e crea le dummy da solo: nella tabella compaiono come `Region[T.South]`. La regione non spiega il saldo.

Reddito e status di studente insieme

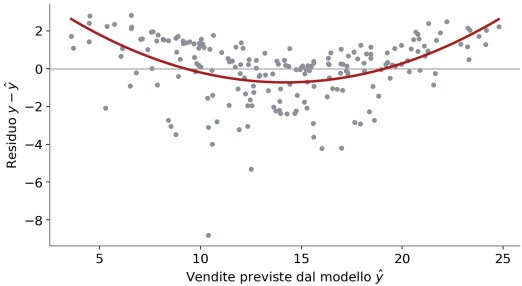


$$\widehat{\text{Saldo}} = 211{,}1 + 5{,}98 \cdot \text{Reddito} + 382{,}7 \cdot \text{Studente}$$

- Due rette **parallele**: stessa pendenza, intercette diverse.
- A parità di reddito, uno studente ha in media 383 $ di saldo in più.
- Ogni 1.000 $ di reddito: +5,98 $ di saldo, studente o no.

Tutti i coefficienti con p-value sotto 0,0001; $R^2 = 0{,}278$.

TV e radio: la sinergia



Residui del modello TV + Radio: la curva dice che la retta sbaglia in modo sistematico.

Aggiungiamo il prodotto dei due budget:

$$\text{Vendite} = \beta_0 + \beta_1 \text{TV} + \beta_2 \text{Radio} + \beta_3 \, \text{TV} \times \text{Radio}$$

- $\hat{\beta}_3$ = 0,0011, p-value < 0,0001.
- R^2 da 0,897 a **0,968**; RSE da 1,68 a 0,94.
- 1.000 $ in TV rendono 19 + 1,1 × Radio unità: più radio c'è, più rende la TV.

È la risposta alla sesta domanda del direttore marketing: i due mezzi insieme rendono più della somma delle parti.

Prima di decidere: cinque controlli

1. **Estrapolazione**: la previsione vale solo dentro l'intervallo dei dati osservati.
2. **Non linearità**: se i residui disegnano una curva, la retta è la forma sbagliata.
3. **Valori anomali**: pochi mercati estremi possono spostare tutta la retta. Guardare sempre il grafico.
4. **Predittori correlati tra loro**: i coefficienti diventano instabili e difficili da leggere, come i giornali con la radio.
5. **Associazione, non causa**: il coefficiente dice cosa succede in media tra mercati diversi, non cosa succede se cambiamo il budget.

Un'AI ti stima il modello in tre secondi. Questi cinque controlli restano a chi firma la decisione.

LAB 2 · Vendite di seggiolini auto

LAB Quali leve muovono le vendite?

Un produttore di seggiolini auto vende in 400 negozi. Vuole capire quanto contano prezzo, pubblicità e posizione sugli scaffali, per decidere dove investire.

Dati: `carseats.csv`

- `Sales`: vendite (migliaia di unità), la variabile da prevedere
- `Price`, `CompPrice`: prezzo nostro e del concorrente; `Advertising`: budget locale (migliaia di $)
- `Income`, `Population`, `Age`, `Education`: caratteristiche della zona
- `ShelveLoc` (Bad, Medium, Good), `Urban`, `US`: variabili qualitative

LAB 2 · Le domande

1. Correlazioni tra `Sales`, `Price` e `CompPrice`: cosa ti aspetti?
2. Stima il modello con tutte le variabili. Quali sono significative? Guarda gli intervalli di confidenza.
3. Leggi i coefficienti di `ShelveLoc`: qual è la categoria di riferimento? Quanto vale uno scaffale buono rispetto a uno cattivo?
4. Togli le variabili non significative: come cambiano R^2 aggiustato ed errore tipico?
5. Un negozio ha prezzo 120, concorrente a 125, pubblicità 10, reddito della zona 70 ed età media 50, scaffale Medium: quante unità prevedi? E con scaffale Good?

Se finisci prima: `lab_credit` (la banca e il saldo delle carte) e `lab_cigarette` (tasse e consumo di sigarette) sono sul sito.

Le domande del direttore marketing, risposte

Domanda	Risposta
C'è una relazione?	Sì: $F = 570$, p-value $< 0{,}0001$.
Quanto è forte?	I tre mezzi spiegano il 90% della variabilità; errore tipico 1.690 unità.
Quanto rende un mezzo?	A parità degli altri: 1.000 $ in TV, tra 43 e 49 unità; in radio, tra 172 e 206.
Quali contano?	TV e radio. I giornali no, a parità degli altri due.
Quanto bene prevediamo?	Bene la media dei mercati, con molta più incertezza il singolo mercato.
C'è sinergia?	Sì: la TV rende di più dove si investe anche in radio.

Intervalli di confidenza al 95% dal modello TV + Radio + Giornali.

Prossima volta

Oggi la Y era un numero: quante unità, quanti dollari.

Spesso la domanda di business è un **sì o no**: il cliente restituirà il prestito? La consegna arriverà in ritardo? Il cliente userà il coupon?

Una retta può dare probabilità sotto zero o sopra uno. Serve un altro modello: la **regressione logistica**.

Da ripassare

Notebook `regressione_advertising`: tutti i numeri di queste slide, riprodotti in Python.

LAB 1 e LAB 2 con le soluzioni, sul sito dopo la lezione.